Building Real-time Image Embedded Map for Edge Robot Navigation

에지 로봇 내비게이션을 위한 실시간 이미지 임베딩 지도 작성

2024 제어로봇시스템학회 학술대회

윤준영
한국항공대학교
a_o@kau.kr

안녕하세요. 에지 로봇 내비게이션을 위한 실시간 이미지 임베딩 지도 작성이라는 주제로 발표하게된
한국항공대학교 석사과정 윤준영입니다.

Contents

1. Research Objectives
2. Related Works
3. Methodology
4. Experiment
5. Limitation
6. Anticipated Benefits

발표는 연구목표, 선행연구, 메또돌로지, 실험, 한계와 기대효과 순으로 진행하겠습니다

What makes robot intelligent?

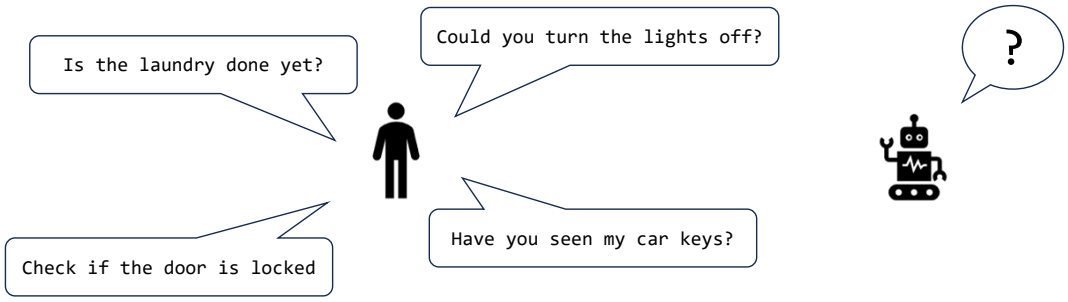

Research Objectives:

- enables robots to navigate with intelligence
- generates goal points from language inputs
- in edge robots

➔ **Utilize VLM**(Visual Language Model) **to build a map**

저희 연구 목표는 로봇으로 하여금 일반적인 지식 수준을 가져, 언어를 통해 네비게이션 할 수 있게
Visual language 모델을 이용하여 image embedding 지도를 작성하는 것 입니다.
또한 이러한 과정을 에지 로봇에서 수행할 수 있게끔, 요구되는 컴퓨팅 파워를 줄이는 것 입니다.

Related Works

(a) SLAM

- VSLAM: ORB-SLAM3, Kimera VIO
- LiDAR SLAM: LIO-SAM, LeGO-LOAM
- Real-time scale mapping and localization
- Post-processing is required for semantic information
  (ex. 3D object detection)

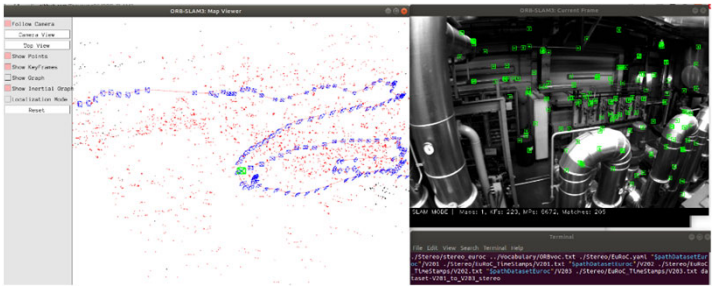

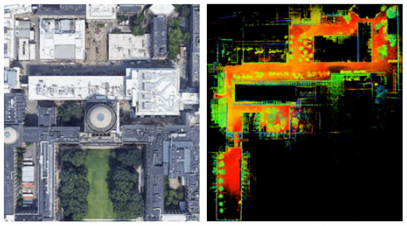

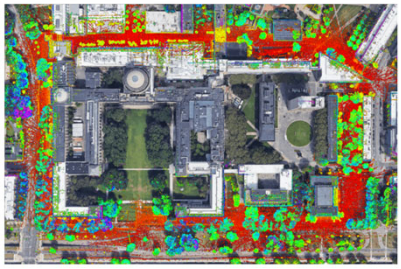

C. Campos et al., "ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial, and Multimap SLAM." T-RO, 2021
T. Shan et al., "LIO-SAM: Tightly-coupled Lidar Inertial Odometry via Smoothing and Mapping." IROS, 2020

선행 연구로는 먼저 SLAM이 있습니다.
VSLAM이나 LiDAR SLAM의 경우 실시간으로 지도 작성이 가능하지만,
해당 frame의 의미를 알기 위해선 3d object detection이나 segmentation
같은 후처리가 필요하여,
저희가 원하는 일반적인 지식 수준의 zero shot navigation goal 생성에는
한계가 있습니다.

Related Works

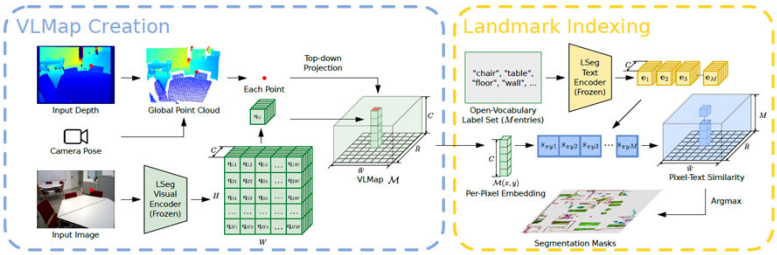

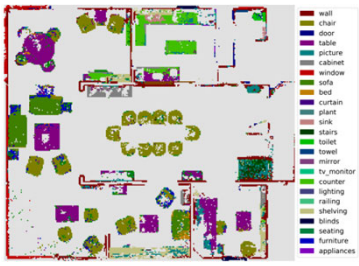

(b) Visual Language Mapping

- Utilizes VLM(Visual Language Model)
- VLMaps, CoWs
- Powerful generalization skills, object-aware
- High computing cost, poor flowtime performance

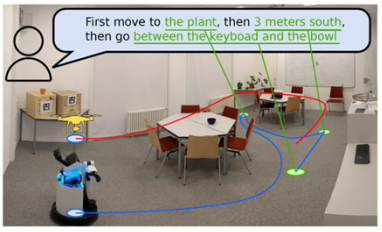

C. Huang et al., "Visual Language Maps for Robot Navigation." ICRA, 2023

이런 단점을 보완하기 위해 visual language model을 사용하여 지도를 작성하려는 시도가 있었습니다.
Visual language model을 먼저 살펴보자면
(VLM 먼저 설명)

Related Works

(c) Visual Language Model

- CLIP, Flamingo
- Integrates visual and textual data
- Enables systems to understand contextual information

  (ex. Image captioning, VQA)

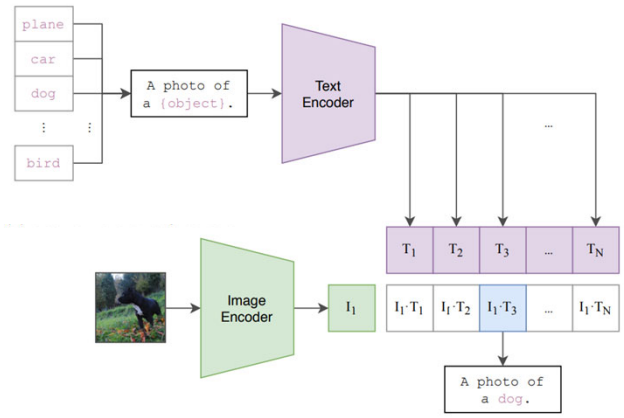

A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision." ICML, 2021

인터넷 스케일로 pretrained된 모델로, 이미지-언어 쌍을 학습하여, 이미지와 언어를 같은 vector space에서 연산할 수 있다는 장점이 있습니다.
사진처럼 사진과 프롬프트를 인코딩하면 그 둘의 확률을 알 수 있습니다.

Related Works

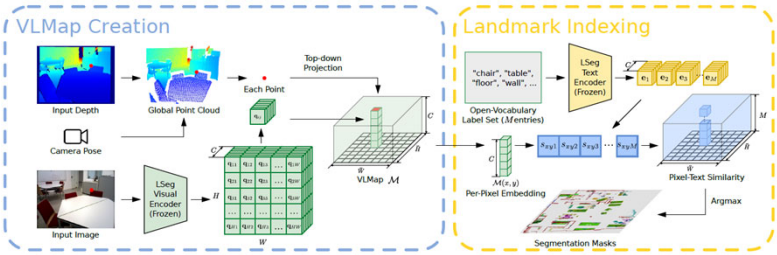

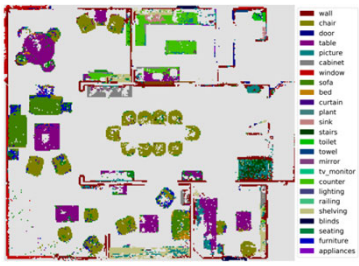

(b) Visual Language Mapping

- Utilizes VLM(Visual Language Model)
- VLMaps, CoWs
- Powerful generalization skills, object-aware
- High computing cost, poor flowtime performance

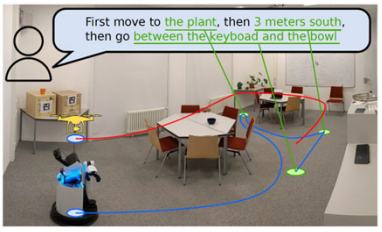

C. Huang et al., "Visual Language Maps for Robot Navigation." ICRA, 2023

VLMaps나 Clip on Wheels같은 모델이 있는데, 이는 강력한 일반화 능력과 semantic aware한 지도를 작성할 수 있다는 장점이 있었지만,
Computing power가 많이 필요하고, 시간이 오래걸린다는 단점이 있어 모바일 로봇에서 사용하기엔 부적절했습니다.
예로써 VLMaps는 30초 정도의 1000프레임짜리 RGBD 시퀀스를 처리하는데 A100으로 15분 정도가 소요되었습니다.

IRAM@KAU

Methodology

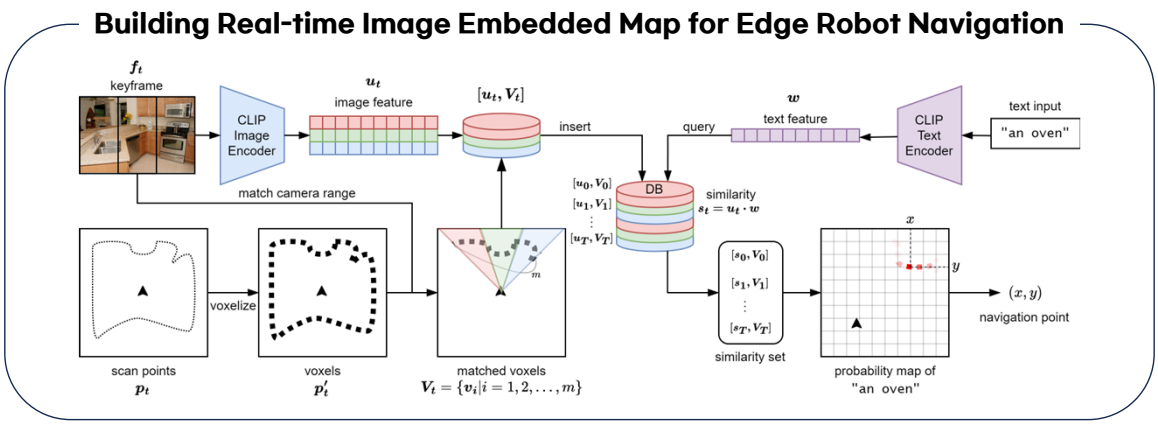

- Run with SLAM(LiDAR or Visual) to obtain the current pose.
- Save the image embedding vector u_t and matched voxels V_t
- With text input query, offers specific probable navigation points.

다음은 전체적인 methodology 입니다.
일반적인 2d lidar slam 또는 vslam 과 더불어 keyframe selection 후 keyframe의 n개의 division에 대해 image embedding vector와 해당 keyframe에서의 viewpoint 또는 관측된 grid point를 db에 저장합니다.
Text input query가 들어오면 db의 feature를 통해 similarity를 계산하여 text와 일치하는 grid를 특정합니다.

Image Embedding in Edge devices?

Requires:

- Run with low computational power
- Fast response time

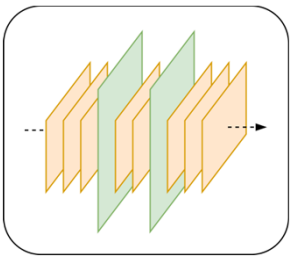

(a) Keyframe Selection

- Similar to the ones in SLAM
- Process only important frames

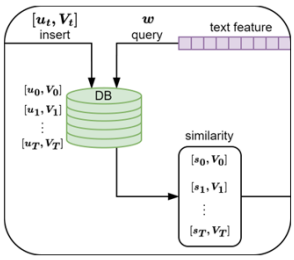

(b) Query-based

- Do not process every grid
- Save features with grids

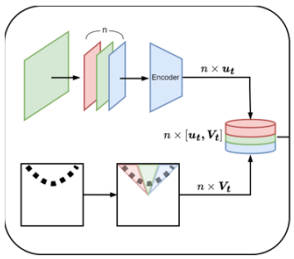

(c) Frame Division

- Divide frame into n subframe
- To get more accurate grid

그럼 image embedding을 사용하여 언어를 통해 모바일 로봇을 제어하기 위해선 어떻게 해야할까요?
적은 컴퓨팅 파워로 임무를 수행하기 위해서 프로세스를 줄이고 flowtime을 향상시키기 위해서
저희는 세 가지 방법을 생각했습니다. Keyframe selection과 query 방식(?????), frame division입니다.
먼저 중복 계산을 피하기 위해 keyframe selection 알고리즘을 도입하였습니다.
이는 SLAM과정에서 사용하는 keyframe decision 에서 착안했습니다???
또한 query(????) 방식을 도입함으로써 맵을 작성할 때 모든 grid에 embedding 을 저장하는 것이 아니라
text input query가 있을 때 grid 를 특정하는 방법을 이용하여 속도를 향상시켰습니다.
또한 grid를 특정할 때 정확도를 높이기 위해 keyframe을 여러 division으로 나누어 처리하였습니다.

Weighted Keyframe Selection

$$f_o(p) = w(d_{o,p}) = d^{0.5}e^{-0.25d+0.15} \quad (1)$$

$$k_{t=kf}: \quad f_t(P_t) - f_{kf-1}(P_t \cap P_{kf-1}) > k_{th} \quad (2)$$

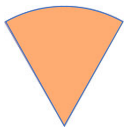

Weighted map based keyframe selection:

- Prevent processing duplicate frames
- k_t represents - new information of frame
- Select proper k_{th} considering map size and memory size

표 1. Experiment of CMAP in real world.

	Simple selection			Weighted selection		
	1/60	1/30	1/10	***k***=1k	***k***=0.1k	***k***=0
keyframes ↓	127.0	243.0	760.7	175.3	364.0	436.0
Accuracy ↑	51.0	54.0	58.0	56.0	56.3	58.7

다음은 keyframe selection 알고리즘에 대한 설명입니다.
가중 맵 기반 키프레임 선정 알고리즘은 중복되는 프레임을 처리하지 않기 위해 고안되었습니다.
(애니메이션) 로봇이 움직이게 되면 관측되는 point가 바뀌게 되는데 중복되는 point를 제외하고 새로 관측된 point에 대해 거리 기반 weighted sum을 이용하는 방법입니다.
중복 point와 새로 관측되는 point는 map에 작성된 obstacle과 그 거리를 이용하여 계산하는데 이때 가중치는 최적 관측 거리에 가까울수록 높게 설정되어 있습니다.
아래의 표를 보면 simple selection은 60프레임 당 1번, 30프레임당 1번, 10프레임당 1번 keyframe으로 선정하였고,
우측의 weighted selection은 k threshold를 1000, 100, 0으로 설정한 경우입니다.
0의 경우는 완전 중복되는 (그러니까 로봇이 정지했을 경우만 제외하여 모든 프레임을 계산한 결과가 됩니다.
결과를 보면 k threshold가 0만 되어도 단순 1/10을 select 했을 때 보다 60%의 연산만으로도 더 좋은 정확도를 나타내었습니다.
로봇이 움직이는 공간이나 sequence 길이에 따라 적절한 k 값을 사용하여 효율적으로 계산할 수 있습니다.

(최적거리에 대한 사진, 설명)

Query-based Method

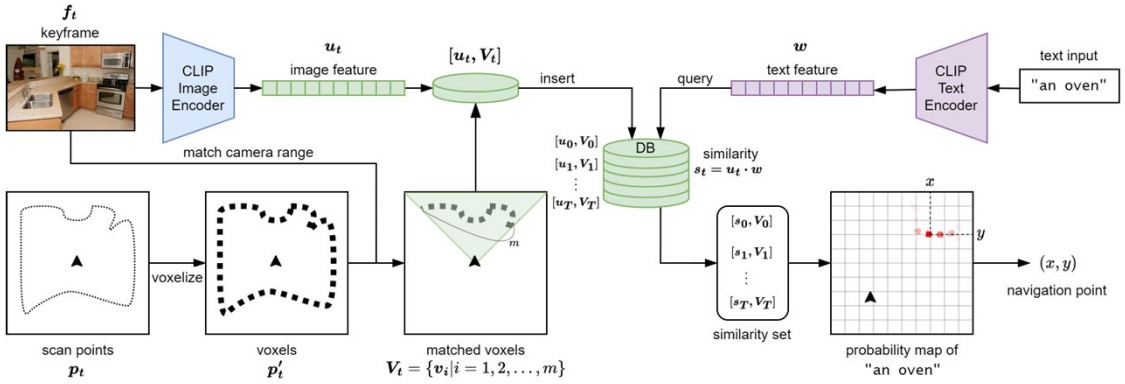

- Save the image embedding vector u_t and matched voxels V_t
- More time and space efficient than mapping features on every grid.
- Process similarity on query to offer specific probable navigation points.

다음은 query(?) 방식에 대한 설명입니다.
여타 알고리즘은 lseg같은 visual language segmentation 모델을 이용하여 pixel마다, grid마다 image embedding을 매핑하는 방식을 사용하였습니다.
이는 정확도를 향상시킬 수는 있었지만 모든 pixel이나 grid에 대해 encoding하고 저장하여야 하므로 연산량이 많아 시간이 오래걸릴뿐만 아니라
저장하는 데이터도 vlmaps의 경우 30초 시퀀스, 14제곱미터 공간에서 (4평정도죠) embedding 데이터의 크기가 2gb정도로 공간 효율도 좋지 않았습니다.
저희는 Query(?) 방식을 도입하여 이런 문제를 해결하였습니다.
맵을 작성할 때 모든 grid에 embedding 을 저장하는 것이 아니라 해당 point를 저장하고,
text input query가 있을 때 query로부터 받은 grid point를 통해 grid를 특정하는 방법을 이용하여 속도를keyframe에서의 embedding과 관측된 향상시켰습니다.
Grid를 특정하는 방식으로는 cummulated average similarity와 frequency(빈도)를 통해 특정하였습니다.(상세한 알고리즘 필요)

Frame Division Method

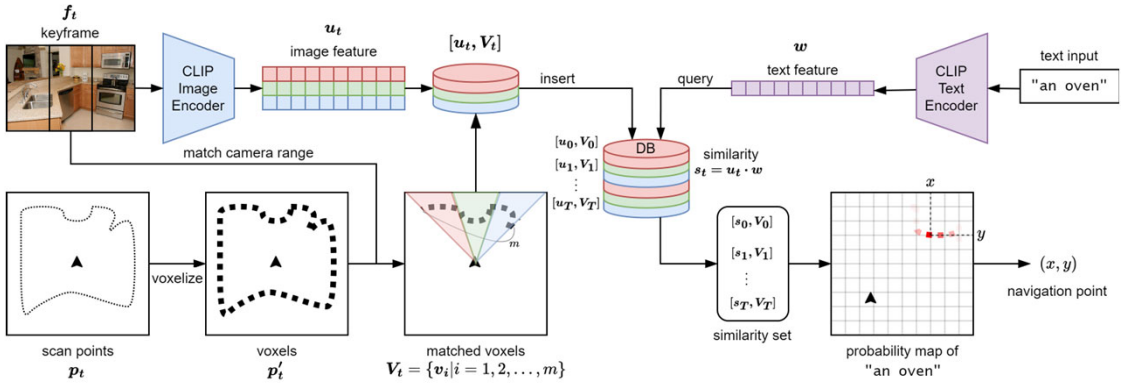

- To resolve accuracy and precision issues, we divide keyframes into n divisions.
- Encode n times more embedding and saves n times more data.
- A proper parameter n is required to maintain accuracy and space efficiency.

Grid에 feature를 저장하는 것이 아니기 때문에 입력된 text에 해당하는 grid를 특정하기 위해선 여러 화각에서 찍힌 물체가 필요했습니다.
이 문제를 저희는 한 keyframe을 n개 division으로 나누어 처리하는 방식을 통해 해결하였습니다.
이렇게 되면 encoding하는 과정에서 처리량이 늘어나고 저장되는 feature의 개수도 n배로 늘어났지만 결과적으로 정확도가 크게 향상되었습니다.
(실험값 table 필요)
실험 결과 한 프레임을 여러 프레임으로 나누어도 batch를 이용하여 일정 vram 수준까지는 처리 속도는 크게 증가하지는 않는 것을 확인했습니다.
물체를 인식할 수 없을 정도로 많이 나누면 정확도가 떨어지므로 적절한 n 값이 필요합니다.

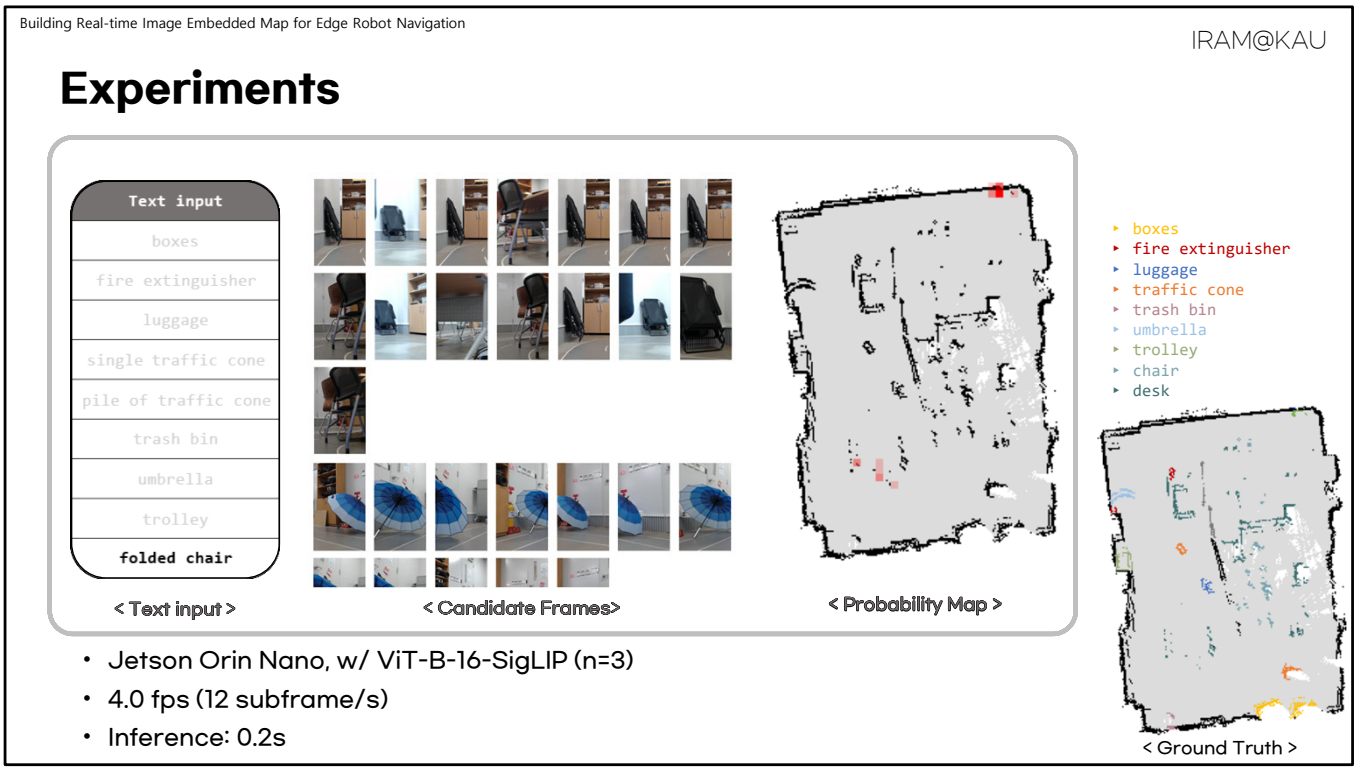

다음은 실험 결과입니다. 입력 text에 따라 similarity를 기반으로 후보 프레임들을 고른 뒤 similarity와 빈도로 각 grid마다 probability를 계산합니다.
Ground truth와 비교하면 grid localizing이 잘 되는 것을 확인할 수 있습니다.
실험은 jetson nano로 진행하였고 사용한 CLIP model은 Vision Transformer Base 16 모델을 사용하였고,
Division이 3일 때 4 fps의 속도가 나왔습니다, text를 입력하였을 때 내비게이션 포인트를 생성하는 속도는 0.2초 정도였습니다.

Limitations

(a) Dependent upon localization quality
- saved upon calculated current location

(b) Space complexity
- Can't handle duplicate frames in different time
- But still better than others (28 MB(ours) << 2 GB(VLMaps))

(c) Several objects detected in same sequences
- Which to pick?

C. Huang et al., "Visual Language Maps for Robot Navigation." ICRA, 2023

실험 결과 이 모델의 한계점은 먼저, robot localization에 의존하기 때문에 위치 추정이 부정확할 경우 결과에 악영향을 미칠 수 있습니다.
두번째로는 이미지를 저장하지는 않지만 feature를 저장하기 때문에 시퀀스가 길어지면 저장하는 용량이 늘어난다는 단점이 있습니다.
하지만 다른 비슷한 알고리즘에 비해선 저장하는 공간이 크게 작습니다.
마지막으로 같은 물체가 많으면 어떤 물체로 이동해야할지 선택하는 추가적인 작업이 필요합니다

Anticipated Benefits & Further Research

(a) Intelligent mapping and navigation
- Zero-shot object-aware navigation
- Text-driven navigation

(b) Fast and lightweighted
- On-device mapping and navigation
- Far lower with given map and text lists(only cosine similarity)

(c) Off-the-shelf weights
- Using open-sourced pretrained models
- For either high-end or more micro robots.

(d) Beyond navigation ➔ Integrated System
- LLM + Navigation + Manipulation
- Chain of thoughts

기대 효과로는 zero-shot으로 사전 학습하지 않아도 지능적으로 물체를 인지할 수 있으며, text로 내비게이션할 수 있고,
빠르고 가벼워서 on-device 매핑과 내비게이션이 가능합니다.
추가적으로 가능한 text list를 미리 인코딩하여 제공할 경우 내적계산밖에 필요하지 않기 때문에 RPi같은 더더욱 낮은 사양의 기기에서도 구동이 가능합니다.
또한 오픈소스 모델을 사용하기 때문에 더 정확한 매핑이 필요할 경우 무겁지만 정확도가 높은 모델로도 구동이 가능합니다.

Anticipated Benefits & Further Research

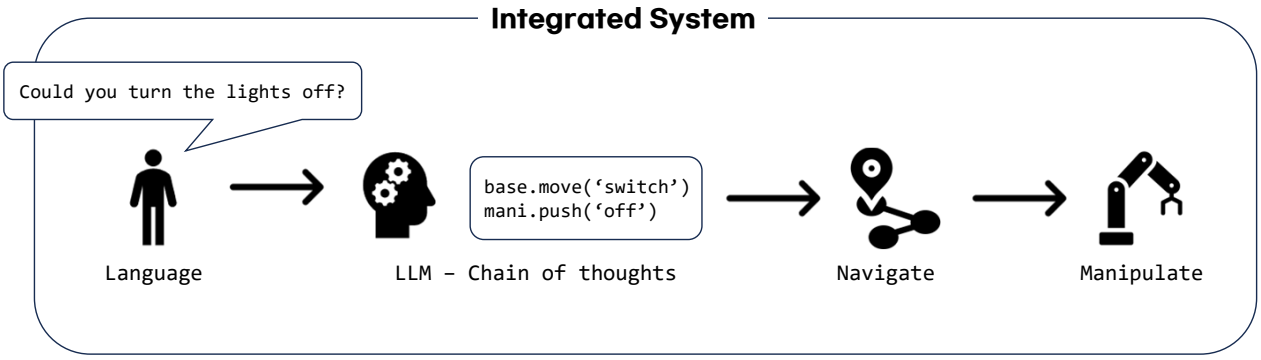

(d) Beyond navigation ➔ Integrated System

- LLM + Navigation + Manipulation
- Chain of thoughts

image: flaticon.com

마지막으로 언어로 내비게이션이 가능하기 때문에 LLM과 manipulator를 이용한 integrated system을 구성할 수 있습니다.
현재는 fine-tuning된 LLM을 이용하여 chain of thought로 지점지점을 이동하며 임무를 수행하는 시스템을 구성하는 연구를 진행하고 있습니다.

IRAM@KAU

Thank You

References:
C. Campos et al., "ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial, and Multimap SLAM." T-RO, 2021
T. Shan et al., "LIO-SAM: Tightly-coupled Lidar Inertial Odometry via Smoothing and Mapping." IROS, 2020
C. Huang et al., "Visual Language Maps for Robot Navigation." ICRA, 2023
A. Radford et al., "Learning Transferable Visual Models From Natural Language Supervision." ICML, 2021
M. Cherti et al., "Reproducible scaling laws for contrastive language-image learning." CVPR, 2023
flaticon.com

이상 발표를 마치겠습니다.